

基于元数据和协同过滤融合的音乐推荐算法

蔡海东 詹昊轩 舒智敏 郭天雄

(铜陵学院 数学与计算机学院, 安徽 铜陵 244061)

摘要: 协同过滤技术是目前推荐系统中最成功、应用最广泛的技术。本文使用基于项目的协同过滤算法,可以在不使用用户个人信息的情况下推荐音乐。为实现更准确的推荐,利用音乐源的元数据预测用户的偏好,最终推荐排名前N位的高偏好音乐。实验结果表明,与不使用元数据时相比,该方法可提高推荐算法的性能。

关键词: 协同过滤; 推荐系统; 音乐推荐; 元数据; 相似度

中图分类号: TP391 文献标识码: A 文章编号: 1003-9767 (2021) 23-051-04

Music Recommendation Based on Metadata and Collaborative Filtering

CAI Haidong, ZHAN Haoxuan, SHU Zhiming, GUO Tianxiong

(School of Mathematics and Computer Science, Tongling University, Tongling Anhui 244061, China)

Abstract: Collaborative filtering technology is the most successful and widely used technology in recommendation system. This paper uses the Project-based Collaborative filtering algorithm, which can recommend music without using users' personal information. In order to achieve more accurate recommendation, the metadata of music source is used to predict users' preferences, and finally recommend the top N high preference music. Experimental results show that this method can improve the performance of recommendation algorithm compared with that without metadata.

Keywords: collaborative filtering; recommendation system; music recommendation; metadata; similarity

0 引言

随着音乐市场的发展,数字音乐数量呈指数级增长,线上音乐服务平台也随之快速兴起,用户可以更便利通过网络聆听音乐^[1]。用户在海量的歌曲中,选择自己喜欢的歌曲变得越来越困难,浪费了大量的时间^[2]。为了快速准确地提供信息,推荐系统是常用的方法之一。推荐系统根据不同用户的兴趣特征,从海量信息中挖掘用户可能感兴趣或需要的资源并进行推荐。

音乐推荐系统(Music Recommender System)已经成为目前的一个热门领域,通过分析用户收听习惯和歌曲特征,推荐满足用户需求和偏好的歌曲^[3]。通过音乐推荐,不仅能主动提供合宜音乐供用户选用,还能提高在线音乐服务质量。王炳祥基于标签和用户特征挖掘用户的音乐偏好进而实现个性化的歌曲推荐^[4]。彭余辉等人针对传统音乐推荐算法的不足,提出一种基于内容和协同过滤加权融合的音乐推荐算法,与传统的推荐算法相比,该加权融合推荐算法计算出的推荐

结果可以更快速地推荐用户感兴趣的音乐^[5]。余莉娟基于改进的Apriori算法,通过对用户信息进行深度学习实现个性化音乐推荐^[6]。考虑到用户个人信息的获取困难,本文在传统推荐技术的基础上,提出一种基于音乐元数据和协同过滤的音乐推荐方法,该方法可在不使用用户个人信息的情况下推荐各种音乐项目。

1 相关概念

1.1 元数据

元数据(Metadata)是“关于数据的数据”,即用来描述某个数据的数据组。元数据可用来反映数据的属性、结构或其他相关信息。例如数字图像可能包含元数据,用于描述图片的大小、颜色深度、图像分辨率等。文本文档的元数据包括文档大小、作者、文档创建时间和文档摘要信息等。网页的元数据可以包括页面内容描述和与内容相关联的关键字等。音乐元数据是与歌曲文件相关的信息集合。

基金项目: 铜陵学院2020年省级大学生创新创业训练计划项目“基于用户评论的音乐歌曲推荐系统”(项目编号:s202010383238)

作者简介: 蔡海东(1997—),男,安徽合肥人,本科在读。研究方向:机器学习。

1.2 最小最大值规范化

最小最大值规范化是数据规范化的一种方式，也叫离差标准化。通过最小最大值规范化可对原始数据进行线性变换，将被挖掘对象的属性数据按比例缩放，使其落入一个特定区间内，如 $[-1,1]$ 或 $[0,1]$ 。

设 \min_A 和 \max_A 分别为属性 A 的最小值和最大值，将 b 的一个原始值 x 通过最小最大值规范化映射成在区间 $[\min_A^{new}, \max_A^{new}]$ 中的值 x' ，其公式为：

$$x' = \frac{x - \min_A}{\max_A - \min_A} (\max_A^{new} - \min_A^{new}) + \min_A^{new} \quad (1)$$

1.3 余弦相似度

余弦相似度(Cosine Similarity)衡量了两个向量的夹角，夹角越小越相似，可用于衡量推荐系统中项目之间的相似度。给定两个向量 a 和 b ，其余弦相似度计算如下：

$$\text{sim}_{ab} = \cos(a, b) = \frac{a \cdot b}{\|a\| \times \|b\|} \quad (2)$$

	项目1	项目2	...	项目 j	项目 n
用户1					
用户2					
...					
用户 i					
用户 m					

用户-项目评分矩阵

式中， $\|a\| \times \|b\|$ 为两个向量的内积， $a \bullet b$ 为两个向量模的乘积。

1.4 基于项目的协同过滤

协同过滤^[7](Collaborative Filtering, CF)是推荐系统最常用的算法，适用于不能简单且充分地用元数据描述的内容，如电影和音乐。协同过滤技术的工作原理是建立一个评分数据库(用户-项目矩阵)，其中包含用户对项目的偏好。然后，通过依据用户的历史行为数据计算用户之间的相似度，将用户与相关兴趣和偏好进行匹配，从而作出推荐。推荐方法如下：为用户建立分组(neighborhood)，并通过分组获取用户 i 尚未评价但已被分组中其他用户评价过的项目 j 推荐给用户 i 。CF产生的建议可以是预测，也可以是推荐。预测通常是一个数值 R_{ij} ，表示用户 i 对项目 j 的预测得分，推荐通常是用户最喜欢的前 N 个项目的列表，如图1所示。

协同过滤技术可以分为两类：基于用户的协同过滤(User-based CF)和基于项目的协同过滤(Item-based CF)。

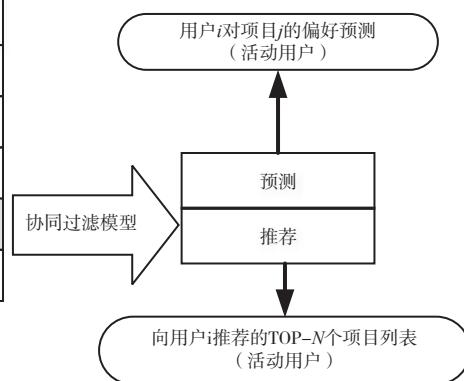


图1 协同过滤算法

基于用户的协同过滤通过比较用户对同一项目的评分来计算用户之间的相似度，然后计算活动用户对某一项目的预测评分，作为与活动用户相似的用户对该项目评分的加权平均值，其中权重是指这些用户与目标项目的相似度。

基于项目的协同过滤利用项目之间的相似性而不是用户之间的相似性来计算预测。通过从用户-项目矩阵中检索活动用户评价的所有项目，建立项目相似度模型，确定检索到的项目与目标项目的相似程度，然后选择最相似的 k 个项目，并确定它们对应的相似度。通过对活跃用户对相似项目 k 的评分进行加权平均来进行预测。通常，使用两种流行的相似性度量方法来计算用户与项目之间的相似度，即基于相关性的相似度(皮尔逊相关系数等)和基于余弦的相似度。

2 本文方法

本文音乐推荐方法由4个阶段组成，即提取音乐元数据、收听频次数据的规范化、基于元数据的音乐间相似性度量、用户偏好预测和音乐推荐。音乐推荐算法使用基于项目的协同过滤算法。

2.1 音乐元数据提取

音乐元数据是包含在音频文件中的信息，用于识别、标记和呈现音频内容。提取音乐元数据的目的是用于度量音乐间的相似性。音乐元数据主要包括音乐的识别信息(曲目编号、歌曲标题、发行日期以及音乐流派等)和音频分析信息(Tempo、Loudness等)。

2.2 收听频次的规范化

用户对每首喜好歌曲的收听频次不同，因此需要对用户收听音乐的频次数据进行标准化处理，对原始数据按照一定的比例进行转换，使之落入到一个特定的区间内。本文采用最小最大值规范化的方法，将规范化后的收听频次数据映射到 $[1,10]$ 。用户 u 对歌曲 i 规范化后的偏好度 $P_{u,i}$ 的计算如下：

$$P_{u,i} = \frac{L_{u,i} - \min(L_u)}{\max(L_u) - \min(L_u)} (S_{\max} - S_{\min}) + S_{\min} \quad (3)$$

式中， $L_{u,i}$ 表示用户 u 对歌曲 i 的收听频次， $\min(L_u)$ 表

示用户 u 收听最少频次, $\max(L_u)$ 表示用户 u 收听最大频次, S_{\max} 表示数据映射范围的最大值, S_{\min} 表示数据映射范围的最小值。

2.3 使用元数据度量音乐间的相似性

本阶段: 首先按照用户最常听的歌曲顺序选择前 M 首歌曲, 同时选择收听过 25 首歌曲以上的前 N 位用户; 其次, 建立 $M \times N$ 的歌曲-用户矩阵, 使用经过最小最大值规范化后的用户音乐偏好数据进行矩阵填充; 再次, 确定目标用户, 区分该用户已听过的音乐和尚未听过的音乐, 将每首歌曲的前 N 位用户的偏好值进行向量化操作后, 用式(2)计算余弦相似度; 最后, 对提取的歌曲元数据同样进行向量化操作并计算余弦相似度, 将两个相似度值相加后的结果作为最终的相似度值。

2.4 偏好预测和音乐推荐

通过使用预测的偏好值, 可从最终生成的歌曲推荐列表中选择 Top- N 首歌曲推荐给用户。是预测偏好值的计算方法如下:

$$P_{u,i} = \frac{\sum_{\text{all similar items}, N} (s_{i,N} * R_{u,N})}{\sum_{\text{all similar items}, N} (|s_{i,N}|)} \quad (4)$$

式中, $P_{u,i}$ 表示目标用户 u 未听歌曲 i 的预测偏好值, $s_{i,N}$ 表示与用户 u 听过歌曲中被判断为与音乐 i 最相似的前 n 首歌曲中歌曲 N 的相似度。 $R_{u,N}$ 是用户 u 听过歌曲 N 的偏好值。

为了获得预测偏好值 $P_{u,i}$, 需要计算具有最高相似度的前 n 首歌曲。其中, n 值由 3 变更为 10。按照预测喜好度高的顺序, 将最终推荐的音乐数以 5 为单位, 数量由 5 变更为 30, 并生成歌曲推荐列表。

3 实验

为验证音乐推荐系统的可行性, 本文使用 Python 语言开发推荐系统, 实验数据使用公开音乐数据集 Million Song Dataset^[8]。该数据集包含百万首歌曲的特征分析、元数据、音乐 ID、用户 ID 和收听频次等数据, 由 The Echo Nest^[9] 提供。其中, 音乐元数据主要取自 Million Song Dataset 数据集中的歌曲摘要数据和流派属性数据。摘要数据由歌曲标题、制作人和发行日期等基本信息和音频分析信息组成; 流派属性数据由标识符和音乐流派组成。实验中, 仅提取摘要数据和流派属性数据都存在的音乐数据, 并将提取的音乐收听频次数据使用最小最大值规范化进行标准化处理, 将数据映射到 [1,10]。

为了进行推荐, 按照用户最常听歌曲的顺序选择了前 100 首歌曲, 并筛选了收听过 25 首歌曲以上的前 500 位用户的 10 272 条数据。实验中, 将 70% 数据作为训练数据集, 30% 的数据作为测试数据集, 对应数据量分别为 7190 和 3082。

使用训练集计算音乐间的相似度和预计偏好度, 并生成向目标用户推荐的音乐列表。将生成的预期偏好和推荐音乐

列表与测试集进行比较, 以验证推荐方法的性能。实验发现, 在预测音乐偏好时, 当相似歌曲的数量指定为 10 时, 推荐系统性能最优。实验中, 相似歌曲的数量固定为 10, 将预测偏好度最高的音乐 Top- N 从 5 变更为 30 (变化步长为 5), 将本文所提推荐方法的性能与传统的项目协同过滤推荐方法性能作比较。

实验结果使用精度^[10] (precision)、召回率^[10] (recall) 和 F1^[10] 衡量。精度表示推荐系统推荐的项目中用户实际偏好的项目比例, 召回率则表示用户偏好的项目中实际推荐的项目比例。精度和召回率可由式(5)、式(6)求得:

$$\text{precision} = \frac{TP}{TP + FP} \quad (5)$$

$$\text{recall} = \frac{TP}{TP + FN} \quad (6)$$

式中: TP 表示推荐项目中实际偏好的项目数; FP 表示推荐项目中不喜欢的项目数。 $TP+FP$ 表示系统推荐的音乐总数; FN 表示用户喜好但系统没有推荐的项目数; $TP+FN$ 表示用户收听的音乐总数。

$F1$ 值的计算公式如下:

$$F1 = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \quad (7)$$

实验结果如表 1 所示。

表 1 推荐歌曲数量 Top- N 变化的精度、召回率和 $F1$ 值

Top- N	传统方法			本文方法		
	精度	召回率	$F1$	精度	召回率	$F1$
5	0.09	0.06	0.07	0.12	0.09	0.10
10	0.09	0.13	0.11	0.11	0.16	0.13
15	0.09	0.20	0.13	0.10	0.22	0.14
20	0.09	0.27	0.14	0.10	0.28	0.15
25	0.09	0.33	0.14	0.10	0.34	0.15
30	0.09	0.40	0.15	0.10	0.41	0.15

表 1 显示了根据推荐歌曲数量 Top- N 变化的精度、召回率和 $F1$ 值。当 Top- N 接近 30 时, 传统推荐方法与本文提出的推荐方法的性能差异较小, 但 Top- N 为 5 ~ 15 时, 所提方法表现出优异的性能。

4 结语

为了减少用户选择自己喜欢的音乐的困难, 本文提出使用收听频次数据和音乐元数据来推荐音乐的方法。所提方法与传统基于项目的协同过滤推荐相比, 具有更好的推荐性能。为了在实际的音乐推荐中应用, 需要能够快速计算音乐之间的相似度, 并生成推荐列表。适当地抽样数据, 则有望对提高实际音乐推荐性能作出贡献。另外, 若后续能利用元数据的类型属性在各个属性中寻找最佳权重值, 则推荐结果会更加符合用户需要。

参考文献

- [1] 阮俊宇. 我国数字音乐产业发展现状及其发展策略 [J]. 临

- 沂大学学报,2014,36(5):85-87.
- [2]王东雨.音乐推荐系统性能调查探究[J].情报工程,2015,1(6):113-119.
- [3]谭学清,何珊.音乐个性化推荐系统研究综述[J].现代图书情报技术,2014(9):22-32.
- [4]王炳祥.基于协同过滤的歌曲推荐算法研究[J].数字技术与应用,2019,37(10):126-127.
- [5]彭余辉,张小雷,孙刚.基于内容和协同过滤加权融合的音乐推荐算法[J].安庆师范大学学报(自然科学版),2021,27(2):44-48.
- [6]余莉娟.基于深度学习的个性化音乐推荐算法研究[J].微型电脑应用,2020,36(10):140-143.
- [7]江水.基于协同过滤技术推荐系统的探究[J].计算机技术与发展,2021,31(11):1-7.
- [8]LIN Y H,CHEN H H.Tag propagation and cost-sensitive learning for music auto-tagging[Z].2020.
- [9]ANDERSEN J S.Using the Echo Nest's automatically extracted music features for a musicological purpose[C]// International Workshop on Cognitive Information Processing,2014.
- [10]焦伶俐.基于深度学习的音乐数据分析和个性化推荐[D].大连:大连理工大学,2021:19-21.

(上接第 50 页)

表 2 10 s 预报误差比较

数据样本长度	误差指标	MCOV+NN	AR	NN	Wiener
20 s	平均误差	0.005 9	0.183 8	0.007 6	0.016 0
	标准差	0.064 7	0.134 9	0.094 4	0.110 3
	执行时间	0.232 7	0.336 0	0.337 0	0.994 0
40 s	平均误差	0.006 0	0.172 9	0.025 6	0.018 2
	标准差	0.073 5	0.135 8	0.134 5	0.082 0
	执行时间	0.268 8	0.340 9	0.433 7	1.026 3

注: 平均误差和标准差的单位为°, 执行时间的单位为 s。

由比较结果可以看出, 本文提出的船舶运动预报方法在给出的海况条件下能够达到较好的预报效果。当使用 40 s 长度的运动测量数据时, 其 5 s 预报时预报结果的平均误差为 0.003 0°, 预报的标准差为 0.024 1°; 10 s 预报时预报结果的平均误差为 0.006 0°, 预报的标准差为 0.073 5°。同时, 该方法在运动测量数据较少时(20 s)也能保持较好的预报效果。其 5 s 预报时预报结果的平均误差为 0.001 8°, 10 s 预报时预报结果的平均误差为 0.005 9°, 预报的标准差分别为 0.017 1° 和 0.064 7°。除个别指标外(20 s 数据长度、5 s 预报时的算法执行时间), 其预报结果的平均误差、标准差和算法执行时间均最小。可以看出, 该预报方法在不同的条件(预报时间、数据样本)下均能获得较好的预报效果, 因而可以更好地适应海况的变化。同时, 上述预报结果也要优于 AR、NN 和 Wiener 等预报方法, 在海情变化较为复杂的条件下也能更好地满足预报要求。

4 结语

对船舶的摇荡运动进行预报研究, 对于开展船舶安全航行、舰载机起降、舰船补给等海上作业活动具有重要的意义。本文提出一种基于修正协方差法和神经网络的船舶运动预报方法, 能够实现海浪环境下较为准确的船舶运动预报, 且对海况的变化具有一定的适应能力, 有效提高了复杂海况条件

下海上作业活动的安全性。

参考文献

- [1]王科俊,姚绪梁,金鸿章.海洋运动体控制原理[M].哈尔滨:哈尔滨工程大学出版社,2007:78-80.
- [2]张俊峰.基于谱估计方法的船舶纵向运动建模预报研究[D].哈尔滨:哈尔滨工程大学,2008:23.
- [3]张今龙,叶家玮,魏栋.基于时间序列法的舰船运动预报实验研究[J].航海工程,2008,37(6):13-16.
- [4]YANG X,POTA H,GARRATT M,et al.Ship Motion Prediction for Maritime Flight Operations[J].IFAC Proceedings Volumes,2008,41(2):12407-12412.
- [5]范海平.基于卡尔曼滤波技术的船舶横摇预测方法研究[D].哈尔滨:哈尔滨工程大学,2008:36.
- [6]CHUNG J C,BIEN Z,KIM Y S.Note on ship-motion prediction based on wave-excitation input estimation[J].IEEE Journal of Oceanic Engineering,1990,15(3):244-250.
- [7]PJF A,JTG A,TL B,et al.Motion planning and control of robotic manipulators on seaborne platforms[J].Control Engineering Practice,2011,19(8):809-819.
- [8]张艳,李世鹏,荣晶晶,等.一种基于参数估计的自适应舰船运动预报方法[J].船舶力学,2012,16(7):759-766.
- [9]王晓莉,王典洪,陈分雄.自回归谱 Marple 算法的频率估计分析[J].理论与算法,2013(15):33-35.
- [10]LARRY M.A new autoregressive spectrum analysis algorithm[J].IEEE Transaction on Acoustics, Speech, and Signal Processing,1980,28(4):441-454.
- [11]张泽旭.神经网络控制与 MATLAB 仿真[M].哈尔滨:哈尔滨工程大学出版社,2011:53.