

本文引用格式：卢振业,杜玉晓.融合情感的异构图神经网络音乐会话推荐算法[J].自动化与信息工程,2025,46(3):9-16.

LU Zhenye, DU Yuxiao. Emotion-enhanced heterogeneous graph neural network for music session-based recommendation algorithm[J]. Automation & Information Engineering, 2025,46(3):9-16.

# 融合情感的异构图神经网络音乐会话推荐算法\*

卢振业 杜玉晓

(广东工业大学自动化学院, 广东 广州 510006)

**摘要：**针对匿名用户或新用户因缺少历史数据，仅根据当前会话进行音乐推荐方式单一、未考虑情感因素影响用户选择等问题，提出融合情感的异构图神经网络音乐会话推荐算法。该算法根据所有用户的历史数据和当前会话构造基于图神经网络的会话推荐，结合音乐情感因素，为匿名用户或新用户推荐更加准确的音乐。实验结果表明，在 Nowplaying 数据集上，该算法与次优的基于图神经网络的会话推荐算法相比，P@20 提高了 2.1%，MRR@20 提高了 6.8%，有效提升了算法推荐性能。

**关键词：**会话推荐；异构图神经网络；音乐情感；匿名用户推荐

中图分类号：TP391.3

文献标志码：A

文章编号：1674-2605(2025)03-0002-08

DOI：10.12475/aie.20250302

开放获取

## Emotion-enhanced Heterogeneous Graph Neural Network for Music Session-based Recommendation Algorithm

LU Zhenye DU Yuxiao

(School of Automation, Guangdong University of Technology, Guangzhou 510006, China)

**Abstract:** To address the limitations of current music session-based recommendation methods for anonymous or new users—such as simplistic recommendations based solely on short-term sessions and neglect of emotional factors influencing user choices—this study proposes an emotion-enhanced heterogeneous graph neural network for music session-based recommendation algorithm. The algorithm constructs a session-based recommendation system using historical data from all users and current sessions via graph neural networks, integrating musical emotional semantics to provide more accurate recommendations for anonymous/new users. Experimental results on the Nowplaying dataset demonstrate that, compared to the suboptimal GNN-based session recommendation method, the proposed algorithm achieves a 2.1% improvement in P@20 and a 6.8% increase in MRR@20, effectively enhancing recommendation performance.

**Keywords:** session-based recommendation; heterogeneous graph neural network; music emotion; anonymous user recommendation

### 0 引言

信息技术的飞速发展，如 5G、智能手机、云服务等，为音乐传播带来了前所未有的机遇。根据酷狗音乐发布的《2023 年度音乐生活白皮书》显示，2023 年新歌总量突破了 2 600 万首，平均约每秒产出一首新歌<sup>[1]</sup>。随着音乐作品数量的不断增长，在有限的时间和认知资源下，用户有效筛选音乐变得越来越困难。

而推荐系统<sup>[2]</sup>通过分析用户偏好和行为模式，向用户推送符合其兴趣的音乐，有效缓解了信息过载的困境，提升了用户的音乐体验。然而，推荐系统面对匿名用户或新用户时，由于缺乏历史数据作为参考，推荐效果不尽如人意<sup>[3-4]</sup>。

基于会话的推荐主要利用当前会话中的交互信息来生成推荐。文献[5]于 2015 年首次将循环神经网

\* 基金项目：国家自然科学基金项目（61976059、61640213）

络 (recurrent neural network, RNN) 应用于会话推荐, 提出基于 RNN 的会话推荐模型, 其采用多层门控递归单元来模拟用户与音乐项目的交互序列, 即使缺乏用户的历史数据, 也能准确捕捉用户的短期兴趣并生成推荐。文献[6]提出基于注意力机制的会话推荐模型, 其将注意力机制与门控循环单元 (gated recurrent unit, GRU) 编码器相结合, 捕捉会话序列中不同项目的重要性和依赖关系, 自动学习用户的兴趣变化和项目之间的相关性, 并生成个性化的推荐结果。文献[7]提出基于注意力机制的短期记忆网络推荐模型, 通过记忆网络获取用户的当前兴趣特征。除 RNN 外, 卷积神经网络 (convolutional neural networks, CNN) 也被广泛应用于会话推荐。文献[8]提出基于内容特征的三维 CNN 协同过滤模型, 利用 CNN 提取用户行为序列的局部特征, 并结合内容特征来增强推荐的准确性。然而, 上述基于深度学习的会话推荐方法主要关注相邻项目的序列建模, 难以处理非连续项目之间的复杂转换, 限制了推荐性能的进一步提升。

基于图神经网络的会话推荐 (session recommendation based on graph neural networks, SR-GNN) 算法<sup>[9]</sup>可根据用户的历史数据和当前会话, 捕捉用户兴趣变

化和项目之间的关联, 提高了推荐的准确性和个性化程度。随着 SR-GNN 算法的深入研究, 学者们提出了许多改进算法, 如基于 GNN 的会话行为建模算法<sup>[10]</sup>、融合社交关系信息的图推荐模型<sup>[11]</sup>、以及引入多粒度用户意图建模的强化 GNN<sup>[12]</sup>等。然而, 上述算法仍存在冷启动和数据稀疏等问题<sup>[13]</sup>。

在音乐推荐领域, 考虑到情感是影响用户选择的重要因素, 本文提出一种融合情感的异构 GNN 音乐会话推荐算法 (以下简称“音乐会话推荐算法”)。首先, 通过异构 GNN 对用户播放音乐行为进行建模, 学习用户长、短期音乐偏好; 然后, 对音频数据和歌词文本进行音乐情感分析, 生成音乐情感向量; 最后, 将用户播放音乐行为与音乐情感向量结合, 利用融合推荐模型以期提供更精准的个性化音乐推荐。

## 1 算法架构与步骤

音乐会话推荐算法先为当前会话的用户建立匿名用户异构会话图, 再根据所有用户的历史会话构建一个用户-音乐项目会话图, 最后通过注意力机制引入音乐情感向量, 提高音乐推荐的准确性。音乐会话推荐算法框架如图 1 所示。

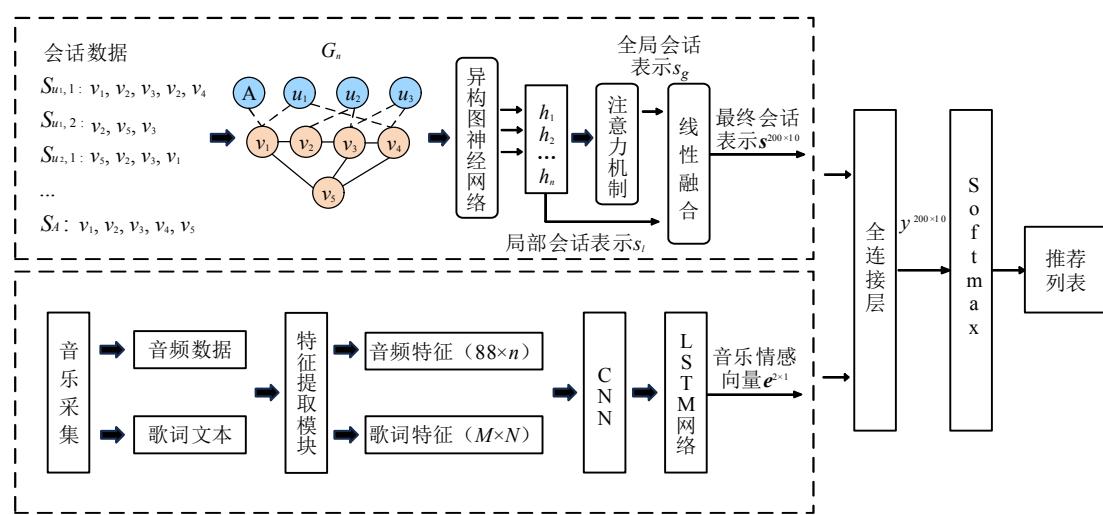


图 1 音乐会话推荐算法框架图

假设当前会话中, 用户播放的音乐集合为  $V$ , 用户播放的第  $i$  首音乐为  $v_i$ , 对应的会话序列为  $S = \{v_1, v_2, \dots, v_n\}$ , 则音乐会话推荐算法的具体步骤如下:

- 1) 将用户的每次播放音乐行为视为一次会话,

并以此构建匿名用户异构会话图  $G_n$ , 其主要包含用户节点和音乐节点, 这两类节点蕴含不同音乐项目之间的转换信息;

2) 利用异构 GNN 提取  $G_n$  中的节点特征, 有效捕捉不同类型节点之间的复杂关系, 从而更准确地表征用户与音乐之间的互动和转换情况;

3) 利用注意力机制对音乐节点的向量表示  $\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_n$  进行加权, 生成全局会话表示  $s_g$ ; 通过线性融合模块将全局会话表示  $s_g$  与上下文信息整合, 得到的最终会话表示  $\mathbf{s}^{200 \times 10}$  作为表征用户短期兴趣与行为偏好的向量表示;

4) 从音频数据和歌词文本中分别提取音频特征和歌词特征, 并利用 CNN 与长短时记忆 (long short-term memory, LSTM) 网络提取音乐情感特征, 生成音乐情感向量  $\mathbf{e}^{2 \times 1}$ ;

5) 将最终会话表示和音乐情感向量输入全连接层, 通过非线性转换得到一组  $200 \times 10$  的向量, 即候选推荐音乐列表;

6) 将候选推荐音乐列表输入 Softmax 预测层, 计算音乐集合  $V$  中各音乐的推荐概率, 最终选取得分最高的若干音乐作为推荐结果。

## 1.1 会话图构建

### 1.1.1 匿名用户异构会话图构建

设当前匿名用户的会话序列为  $S = \{v_1, v_2, \dots, v_i\}$ 。其中,  $v_i$  表示用户播放的第  $i$  首音乐。若将用户在当前会话中播放的音乐看作节点, 不同音乐的播放顺序对应为有向边, 则用户的音乐播放行为序列可转化为一个有向的匿名用户异构会话图, 如图 2 所示。

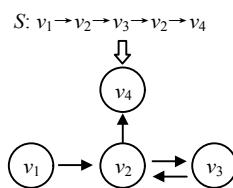


图 2 匿名用户异构会话图

### 1.1.2 用户-音乐项目会话图构建

异构 GNN 通过异构图注意力机制, 有效学习和

表示异构会话图中节点和边的信息。本文将所有的用户和音乐项目构建一个用户-音乐项目会话图, 并将其作为本文会话图的初始节点特征。用户-音乐项目会话图如图 3 所示, 其中,  $u_1, u_2, u_3$  分别表示用户 1、用户 2、用户 3, A 表示匿名用户。

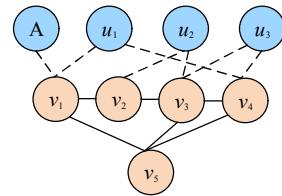


图 3 用户-音乐项目会话图

## 1.2 异构 GNN

为了能够对异构会话图中的节点关系与语义信息进行有效建模, 需将其中各节点及其关联关系转化为统一的向量表示, 以提取不同类型节点间的潜在依赖, 从而支持后续的用户偏好建构与推荐。

异构 GNN 可有效传递不同类型节点之间的信息。由于用户节点和音乐节点对推荐任务的影响不同, 因此异构 GNN 先分别聚合异构邻居和同种类型邻居的节点信息, 再将所有类型的邻居节点信息聚合成一个向量, 即节点的向量表示, 具体计算过程如下:

$$f_1(v) = \frac{\sum_{arr \in Arr} \{\vec{\text{LSTM}}[FC(arr)] \oplus \vec{\text{LSTM}}[FC(arr)]\}}{|Arr|} \quad (1)$$

$$f_2(v) = \frac{\sum_{t \in t} \{\vec{\text{LSTM}}[f_1(v)] \oplus \vec{\text{LSTM}}[f_1(v)]\}}{|t|} \quad (2)$$

$$a^{v_i, t} = \frac{\exp\{\text{LeakyReLU}(U[f_2(t) \oplus f_1(v_i)])\}}{\sum_{f_j \in f_2(t) \cup f_1(v_i)} \exp\{\text{LeakyReLU}(U[f_j \oplus f_1(v_i)])\}} \quad (3)$$

$$\mathbf{h}_i = \sum_{f_j \in f_2(t) \cup f_1(v_i)} a^{v_i, t} f_j \quad (4)$$

式中:  $f_1(v)$  为异构邻居的节点信息;  $f_2(v)$  为同种类型邻居的节点信息;  $f_3(t)$  为汇聚了所有节点的节点信息集;  $a^{vi,t}$  为每种类型的节点对节点  $v_i$  的注意力权重;  $\mathbf{h}_i$  为节点  $i$  的向量表示;  $arr$  为异构会话图中的节点,  $Arr$  为异构会话图中节点的属性集;  $t$  为向量, 包含用户和音乐两种类型;  $f_4$  为  $f_3(t)$  集合与和  $f_1(v)$  集合的并集;  $FC$  为向量转换层, 可将节点的属性转换为向量, 如文字属性采用 one-hot 编码, 图像属性采用 CNN 模型等; LSTM 为 LSTM 架构获取特征的相关性; LeakyReLU 为激活函数;  $U$  为注意力参数。

### 1.3 会话表示

将当前会话中最后一首音乐  $v_n$  的向量表示  $\mathbf{h}_n$  作为局部会话表示  $s_l$ :

$$s_l = \mathbf{h}_n \quad (5)$$

全局会话表示  $s_g$  需了解当前会话中的所有音乐之间的相关性信息, 计算公式为

$$s_g = \sum_{i=1}^n a_i \mathbf{h}_i \quad (6)$$

$$a_i = \mathbf{W}^T \sigma(\mathbf{W}_1 v_i + \mathbf{W}_2 v_n + \mathbf{c}) \quad (7)$$

式中:  $a_i$  为音乐  $i$  的节点表示权重系数;  $\mathbf{W}^T$  为注意力权重的投影矩阵, 用于计算节点间的相似度;  $\mathbf{W}_1$ 、 $\mathbf{W}_2$  为权重矩阵;  $\mathbf{c}$  为偏置向量;  $\sigma$  为激活函数, 用于引入非线性变换, 以增强模型对复杂关系的建模能力。

会话表示计算公式为

$$s = \mathbf{W}_3 [s_l; s_g] \quad (8)$$

式中:  $\mathbf{W}_3$  为调节局部会话表示和全局会话表示的权重。

在最终会话表示  $\mathbf{s}^{200 \times 10}$  中, 200 为异构 GNN 的节点数量, 10 为每个会话序列的最大长度上限。

### 1.4 音乐情感提取

音乐是一种充满情感的艺术形式。情感不仅包含在音乐的旋律中, 还隐藏在歌词里。为了更准确地对

音乐进行情感分类, 需同时提取音乐的音频特征和歌词特征。

#### 1.4.1 音频特征提取

为了提升音频数据的质量和可用性, 进一步提高音频特征的提取效果, 先对音乐进行降噪、均衡化等预处理, 再采用开源多媒体特征提取器 open SMILE 提取音频特征, 主要包括音量、频谱、梅尔频率倒谱系数等。

#### 1.4.2 歌词特征提取

歌词特征提取是捕捉歌词文本中的情感词汇、情感强度、情感表达方式等方面的特征, 主要步骤如下:

1) 对歌词文本进行预处理, 包括去除标点符号、停用词和特殊字符等, 以减少噪声并规范化歌词文本;

2) 采用 word2vec 对预处理后的歌词文本进行分词处理, 分割成单词或词组, 以获取歌词文本中的词向量表示;

3) 结合情感词典、情绪标签词表等外部资源, 筛选具有情感倾向的核心单词, 并统计其出现频率、分布位置和词性组合等特征; 使用池化(如平均池化或加权池化)操作将词向量表示聚合为固定长度的歌词向量表示, 为后续的情感判别与融合建模提供输入。

#### 1.4.3 CNN 中的情感特征提取

为了有效提取音乐的情感特征, 本文采用 CNN 分别对音频特征与歌词特征进行处理。首先, CNN 对音频特征和歌词特征进行卷积、归一化等操作, 提取局部模式并增强情感特征表达能力; 然后, 在 Sigmoid 激活函数中引入非线性变换, 以增强 CNN 算法对复杂情感的表达能力; 最后, 利用最大池化操作对卷积输出进行下采样, 压缩特征维度、保留关键信息, 同时减少冗余干扰。该过程为音乐情感向量提供了高质量的深层语义特征表示。

#### 1.4.4 LSTM 网络中的情感时序建模

LSTM 网络能够有效处理音频数据中的时间依赖关系, 捕捉时序特征; 通过自适应学习单词之间的依赖关系, 捕捉歌词文本中单词之间的长距离依赖关系, 从而更好地建模上下文信息。双向长短时记忆(bidirectional long short-term memory, BiLSTM) 网络同时

考虑过去和未来的信息，能够更全面地理解歌词特征与音频特征的模式和结构。

在 BiLSTM 网络中，通过注意力机制融合处理音频特征和歌词特征，并生成一个二维向量  $e$ ，即效价和唤醒度。通过对效价和唤醒度的量化描述，可判别音乐的情感类别，如积极、消极、中性、快乐、忧伤、激昂、平静等，作为音乐会话推荐算法的辅助语义信息输入。

### 1.5 融合推荐

全连接层将最终会话表示 ( $s^{200 \times 10}$ ) 和音乐情感向量 ( $e^{2 \times 1}$ ) 拼接生成一个长向量 ( $I^{1 \times 2002}$ )。在融合推荐模型训练过程中，通过反向传播算法进行学习、自动调整权重，从而对最终会话表示与音乐情感向量输入进行特征提取、非线性变换和映射。全连接层模型如图 4 所示。

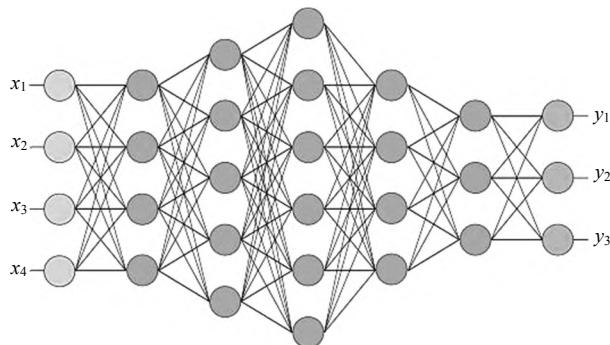


图 4 全连接层模型图

将全连接层拼接生成的长向量进行非线性转换，可得到候选推荐音乐列表  $y$ ：

$$y = W_4(s \oplus e) \quad (9)$$

式中： $y$  为一个  $1 \times 100$  维的向量，代表 100 首候选推荐音乐； $W_4$  为投影矩阵； $\oplus$  为全连接层。

为了得到候选推荐音乐列表中各音乐项目的预测得分，在预测层利用 Softmax 函数计算 100 首音乐的概率分布  $p$ ，即每首音乐被用户偏好的概率：

$$p = \text{softmax}(y) \quad (10)$$

$$p^i = \frac{e^{z_i}}{\sum_{j=1}^{100} e^{z_j}} \quad (11)$$

式中： $p^i$  为候选推荐音乐列表中第  $i$  首音乐被推荐的概率， $z_i$ 、 $z_j$  为音乐  $i$ 、 $j$  在特征空间  $z$  下的特征向量。

用户下次最可能播放的音乐就是推荐概率最大的音乐，则目标函数可表示为对数似然：

$$L = -\sum_{k=1}^N \ln(p_k) \quad (12)$$

式中： $N$  为训练样本总数， $p_k$  为融合推荐模型对第  $k$  个训练样本生成的音乐推荐概率。

## 2 性能评估与结果分析

### 2.1 数据集

本文采用用户音乐播放行为数据集 Nowplaying<sup>[14]</sup>验证本文提出的音乐会话推荐算法的有效性。该数据集由 Last.fm 平台采集，记录了大量用户在真实环境中的音乐播放行为，包括会话 ID、用户 ID、音乐项目 ID 及时间戳等信息。参照 SR-GNN 模型<sup>[15]</sup>的预处理方法，将该数据中会话长度为 1 首的数据和出现次数少于 5 次的音乐项目过滤掉。将最近一周的数据作为测试集，其余历史数据作为训练集。Nowplaying 数据集预处理结果如表 1 所示。

表 1 Nowplaying 数据集预处理结果

统计项	数值
用户所有历史音乐播放次数/次	1 367 963
训练集包含的用户播放音乐行为数据数量/首	825 304
测试集包含的用户播放音乐行为数据数量/首	89 824
筛选后剩余音乐项目数量/首	60 417
用户平均每次播放的音乐数量/首	7.42

### 2.2 对比算法

为验证本文算法的有效性，将其与以下算法进行对比实验：

- 1) 基于热度的推荐 (popularity-based recommendation, POP) 算法, 通过统计训练集中出现频次最高的  $N$  个音乐项目进行推荐预测;
- 2) 基于项目的 K 近邻 (item-based K-nearest neighbors, Item-KNN) 算法<sup>[16]</sup>, 通过计算相邻音乐项目的相似度, 推荐与历史兴趣相似的音乐项目;
- 3) 因式分解个性化马尔可夫链 (factorizing personalized Markov chains, FPMC) 算法<sup>[17]</sup>, 采用马尔可夫链捕获用户偏好, 推荐下一首可能播放的音乐;
- 4) 基于 GRU 的会话序列推荐 (gated recurrent units for recommendations, GRU4Rec) 算法<sup>[5]</sup>, 基于 GRU 对用户行为序列建模, 挖掘用户短期兴趣, 预测并推荐下一首用户可能感兴趣的音乐;
- 5) 基于神经注意力机制的会话推荐 (neural attentive session-based recommendation, NARM) 算法<sup>[6]</sup>, 在 GRU4Rec 算法中引入注意力机制;
- 6) 短时注意力记忆优先 (short-term attention/memory priority model, STAMP) 算法<sup>[7]</sup>, 依赖当前会话的最后一个音乐项目进行推荐预测;
- 7) 协同会话推荐与并行记忆模块 (collaborative session-based recommendation with parallel memory modules, CSRM) 算法<sup>[14]</sup>, 利用记忆网络将会话推荐转化为图分类问题, 以更好地捕捉会话的复杂依赖关系;
- 8) SR-GNN 算法<sup>[9]</sup>, 先通过 GNN 捕捉当前会话的信息, 再进行下一音乐项目的推荐预测。

### 2.3 评估指标

本文采用会话推荐中常用的 P@20 和 MRR@20 作为算法的性能评估指标。

P@ $k$  (precision) 表示正确推荐音乐项目的比例, 用于评估推荐准确性, 计算公式为

$$P@k = \frac{n_{hit}}{N} \quad (13)$$

式中:  $N$  为推荐的音乐项目数,  $n_{hit}$  为被正确推荐的音乐项目数。

MRR@ $k$  (mean reciprocal rank, MRR) 表示被正

确推荐的音乐项目在候选推荐音乐列表中的排名, 计算公式为

$$MRR@k = \frac{1}{N} \sum_{i \in S_v} \frac{1}{\text{rank}(i)} \quad (14)$$

式中:  $S_v$  为前  $N$  个推荐音乐项目中包含正确音乐项目的样本集, rank( $i$ ) 为音乐项目  $i$  在候选推荐音乐列表中的排名。

### 2.4 对比实验结果

9 种算法在 Nowplaying 数据集上的评估指标如表 2 所示。其中, 每列的最佳结果以粗体显示, 次优结果以下划线显示。

表 2 9 种算法的评估指标

算法	P@20	MRR@20
POP	2.24	0.87
Item-KNN	15.93	4.89
FPMC	7.36	2.80
GRU4REC	7.92	4.46
NARM	18.59	6.73
STAMP	17.66	6.88
CSRM	18.24	6.32
SR-GNN	<u>18.87</u>	<u>7.39</u>
本文算法	<b>19.28</b>	<b>7.89</b>

由表 2 可以看出: 由于 Item-KNN 算法引入了用户相似度, 在 POP、Item-KNN、FPMC 3 种传统推荐算法中取得最好效果; 但考虑到时间顺序对推荐性能的影响, NARM、STAMP 等算法将音乐序列的最后一个音乐项目作为用户的主要偏好, 导致基于 RNN 的推荐算法性能普遍优于传统推荐算法; CSRM、SR-GNN 算法利用其他会话的有效信息, 提升了推荐性能; 本文算法与次优算法 SR-GNN 相比, P@20 提高了 2.1%, MRR@20 提高了 6.8%, 验证了本文算法在会话推荐任务中的有效性。

### 2.5 消融实验

为验证本文算法各模块的有效性, 进行消融实验:

- 1) model-1, 仅使用全局会话表示;
- 2) model-2, 仅使用局部会话表示;

3) model-3, 使用全局会话表示与局部会话表示, 但不加入音乐情感向量;

4) 本文算法, 使用全局会话表示与局部会话表示, 并加入音乐情感向量。

4 种算法的评估指标如表 3 所示。

表 3 4 种算法的评估指标

算法	P@20	MRR@20
Model-1	17.83	6.93
Model-2	18.91	7.46
Model-3	19.01	7.59
本文算法	<b>19.28</b>	<b>7.89</b>

由表 3 可知: 基于短期偏好形成的局部会话表示在推荐过程中作用更明显; 全局会话表示在捕获静态、长期偏好方面具有一定效果, 这两种会话表示相互补充, 可提高算法的推荐性能; 引入音乐情感向量后, 推荐算法性能有所提升, 验证了引入音乐情感向量的有效性。

### 3 结论

为了应对匿名会话冷启动和数据稀疏等挑战, 本文提出一种融合情感的异构 GNN 音乐会话推荐算法。该算法通过构建异构会话图, 更有效地学习所有用户与音乐之间的关系。为了进一步提升算法性能, 引入了音乐情感向量。实验结果表明, 该算法提升了音乐推荐的效果。

然而, 用户播放音乐行为的影响因素众多, 如音乐流派、天气、情景等。因此, 下一步研究将综合考虑上述因素, 进一步提升算法的推荐性能, 有助于更全面地理解和满足用户的多样化需求, 使音乐推荐算法更贴近实际应用场景。

### 参考文献

- [1] 酷狗.2023 年度音乐生活白皮书[R/OL].(2024-01-12)[2024-01-19]. <https://activity.kugou.com/whitebook/v-fd506630/index.html>.
- [2] GOLDBERG D, NICHOLS D, TERRY D, et al. Using collaborative filtering to weave an information tapestry[J]. Communications of the ACM, 1992,35(12):61-70.
- [3] 毛骞,谢维成,乔逸天,等.推荐系统冷启动问题解决方法研究综述[J].计算机科学与探索,2023,16(2):1-14.DOI:10.3778/j.issn.1673-9418.2308044.
- [4] 马福军,胡力勤.密度峰值聚类算法在管廊大数据挖掘中应用[J].机电工程技术,2022,51(2):94-97.
- [5] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks [EB/OL]. arXiv:1511.06939, 2015[2024-06-13]. <https://arxiv.org/abs/1511.06939>.
- [6] LI J, REN P, CHEN Z, et al. Neural attentive session-based recommendation[J].ACM, 2017(CIKM'17):1419-1428. DOI: 10.1145/3132847.3132926.
- [7] LIU Q, ZENG Y, MOKHOSI R, et al. STAMP: Short-term attention/memory priority model for session-based recommendation[J]. SIGKDD Explorations,2018(Udisk): 1812-1820.
- [8] TUAN T X, PHUONG T M. 3D convolutional networks for session-based recommendation with content features[J]. ACM, 2017, (RecSys '17):138-146. DOI:10.1145/3109859.3109900.
- [9] WU S, TANG Y, ZHU Y, et al. Session-based recommendation with graph neural networks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019,33(1):346-353. DOI:10.1609/aaai.v33i01.3301346.
- [10] GUO J, YANG Y, SONG X, et al. Modeling multi-granularity user intent evolving via heterogeneous graph neural networks for session-based recommendation[J]. Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining, 2021, (WSDM'22):343-352. DOI:10.48550/arXiv.2112.13197.
- [11] FAN W, MA Y, LI Q, et al. Graph neural networks for social recommendation[J]. CoRR, 2019, (WWW '19):417-426. DOI: 10.1145/3308558.3313488.
- [12] RUIHONG Q, JINGJING L, ZI H, et al. Rethinking the item order in session-based recommendation with graph neural networks[J]. ACM, 2019, (CIKM '19):579-588. DOI:10.1145/3357384.3358010.
- [13] OUYANG W, ZHANG X, REN S, et al. Learning graph meta embeddings for cold-start ads in click-through rate prediction [J]. ACM, 2021,(SIGIR '21):1157-1166. DOI:10.1145/3404835.3462879.
- [14] WANG M, REN P, MEI L, et al. A collaborative session-based recommendation approach with parallel memory modules [C]//International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2019.DOI:10.1145/3331184.333121

- 
- [15] SONG J, SHEN H, OU Z, et al. ISLF: Interest shift and latent factors combination model for session-based recommendation [C]/Twenty-Eighth International Joint Conference on Artificial Intelligence {IJCAI-19}.2019. DOI:10.24963/ijcai.2019/799.
- [16] SARWAR, BADRUL, KARYPIS, et al. Item-based collaborative filtering recommendation algorithmus[J]. Proceedings of the Tenth ACM International Conference on Information and Knowledge Management, 2001, (CIKM'01), 285-286. DOI: 10.1145/502585.502607.
- [17] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized Markov chains for next-basket recommendation[C]/Proceedings of the 19th International Conference on World Wide Web, WWW 2010, Raleigh, North Carolina, USA, April 26-30, 2010. ACM, 2010. DOI: 10.1145/1772690.1772773.

**作者简介：**

卢振业，男，1998 年生，硕士研究生，主要研究方向：信号处理。

杜玉晓（通信作者），男，1973 年生，博士研究生，副教授，主要研究方向：自动化装备与集成、数字图像处理、医疗器械设备及脑机接口（BCI）技术。E-mail: yuxiaodu@gdut.edu.cn